ThreeQ 系列能量模型系统研究报告：收敛性、训练机制与 MNIST 实验

ThreeQ Research

2026-04-19

摘要

本报告系统整理 ThreeQ 系列能量模型截至当前的理论、实现和实验结论，覆盖基础 ThreeQ、EPThreeQ、DThreeQ、CNNThreeQ/EPCNNThreeQ 及 Dplus 机制诊断。理论部分以固定点推断映射 $T(u;W)$ 的局部 Jacobian 谱半径为核心，给出 $\rho(J) < 1$ 下的局部收敛条件、小步训练更新保持稳定裕度的解释，并通过受控线性母模型补充 $\rho(J) > 1$ 时的指数发散侧证。实验部分汇总 two moons、MNIST small-budget screen、legacy MNIST reproduction、EPThreeQ 调参、DThreeQ longrun/full-data、输入能量与输出监督审计、Dplus/BP/EP 更新方向诊断以及 CNNThreeQ 结构探索。当前证据表明：EPThreeQ 是最稳定的原始 ThreeQ 改进线，MNIST 10k/2k 上可达约 86.5% accuracy；DThreeQ 的 EP/CE-nudge 分支可学习，full-data restore-best 达到约 88.0%，但 final accuracy 存在后期崩塌；Dplus residual-delta 规则尚未呈现 BP-like credit assignment；CNNThreeQ 在结构上自然推广了严格转置对称，但仍缺少充分的可比较多 seed benchmark。

1 研究对象与核心问题

本项目研究一类基于“对称/双向局部预测 + 截断梯度状态更新”的能量模型。它与标准前馈网络的主要差异在于：网络不是一次前向传播得到输出，而是先在每层状态变量上运行局部推断，使相邻层之间的预测残差下降；训练则根据自由相、受扰相或 residual delta 构造权重更新。这个范式的目标不是完全复制 BP，而是在局部状态动力学中形成可训练、可解释、可推广到对称结构的学习规则。

当前研究围绕四个问题展开：

1. ThreeQ inference 什么时候收敛，训练更新什么时候会破坏收敛性；
2. 基础 ThreeQ 与 EPThreeQ 在 two moons 和 MNIST 上的性能差异来自哪里；
3. DThreeQ/Dplus 是否提供了比 EP 更合理的局部 credit assignment；
4. 这类结构能否推广到严格转置共享、卷积/反卷积和更一般的对称能量模型。

2 理论框架：固定点推断与训练稳定性

ThreeQ 母模型将全局状态记为 $u \in \mathbb{R}^n$，局部预测映射写作

$$T(u; W) = \frac{1}{n-1} W g(u), \tag{1}$$

其中 g 是逐元素激活函数。固定点 $u^\star$ 满足

$$u^\star = T(u^\star; W). \tag{2}$$

在固定点附近定义扰动 $\delta = u - u^\star$，局部 Jacobian 为

$$J(u^\star, W) = \frac{\partial T}{\partial u}(u^\star, W) = \frac{1}{n-1} W \operatorname{diag}(g'(u^\star)). \tag{3}$$

命题 1 (局部推断稳定性)**.** *若固定点 $u^\star$ 处满足 $\rho(J(u^\star, W)) < 1$，则离散固定点迭代 $u^{t+1} = T(u^t; W)$ 的线性化扰动满足 $\delta_{t+1} \approx J\delta_t$，并在局部指数收敛。若存在特征值 $|\lambda| > 1$，则沿对应不稳定特征方向的扰动在局部线性化系统中指数增长。*

训练稳定性是上述条件的参数连续性推论。令训练更新为

$$W^+ = W - \eta \nabla_W E(u^\star(W), W). \tag{4}$$

若当前点存在稳定裕度 $\rho(J) \le 1 - \varepsilon$，且梯度范数有界，则足够小的 η 会保持更新后 $\rho(J(W^+)) < 1$。该命题只保证局部 inference 稳定，不保证表示能力、BP-like 更新方向或长程训练不会离开稳定邻域。

3 模型家族

3.1 基础 ThreeQ / Base3Q

基础分层 ThreeQ 使用每层状态 x_i，并通过相邻层双向预测构造局部 residual。下层到上层使用 forward weights，上层到下层使用 backward weights；状态推断通常使用 hard clipping $\operatorname{clip}(x, 0, 1)$ 来维持有界性；训练主线包括 free phase 和 weak/clamped phase，并对受扰相 total energy 或局部 residual 求权重更新。对应代码包括 `Base3Q/`、`Base3QClampWithLinear/` 以及公共实现 `threeq_common/`。

基础 ThreeQ 的优势是结构清楚、局部性强、容易和固定点收敛证明对应；主要问题是 hard clipping 虽然降低局部谱半径，却容易制造状态饱和和弱梯度，且 detach/局部预测会削弱深层监督信号传播。

3.2 EPThreeQ / EPBase3Q

EPThreeQ 将权重目标改为自由相与受扰相能量差：

$$\Delta W \propto -\nabla_W \frac{E(s_\beta, W) - E(s_0, W)}{\beta}. \tag{5}$$

该规则比 direct total-energy objective 更接近 Equilibrium Propagation 的局部学习思想。实验上，EPThreeQ 在 two moons minimal suite 和 legacy MNIST reproduction 中都显著优于 direct ThreeQ。它的主要超参风险是 β 与 weak steps：扰动太弱时信号不足，扰动过强或步数过多时容易出现 early-best 后回退。

3.3 DThreeQ / Dplus

DThreeQ 使用 tanh 状态和双向 residual，比较自由相与受扰相 residual 的变化。Dplus 典型目标为

$$\mathcal{L}_{D+} = \frac{1}{2}\sum_{e} \|r_e^{\beta} - r_e^{0}\|^2. \tag{6}$$

其直觉是：监督扰动应该在局部 residual 中留下可学习的方向信号，从而避免直接依赖 EP 能量差。当前结果显示，DThreeQ 的 EP-nudge/CE-nudge 分支可以在 MNIST 上学习，但 Dplus residual-delta 分支与 BP 更新方向不对齐，尚不能作为主训练规则扩大 benchmark。

3.4 CNNThreeQ / EPCNNThreeQ

CNNThreeQ 将局部双向预测推广到卷积结构：正向边使用 `conv2d`，反向边使用 `conv_transpose2d`，这在结构上自然对应严格转置共享。该方向是从 MLP 对称结构推广到卷积/反卷积能量模型的重要候选，但当前只有 legacy 脚本和小预算 stress screen，缺少独立、多 seed、完整预算的 CNN suite。因此本报告将 CNNThreeQ 作为结构推广证据，而不把它作为当前性能主结论。

4 实验流程与数据来源

本报告只汇总已完成实验，不重新训练模型。主要实验来源包括：

- `AllConnected3QNotTrained` 与受控线性母模型：验证 $\rho < 1$ 收敛和 $\rho > 1$ 发散；
- `experiments/minimal_suite`：two moons 上直接 ThreeQ 与 EPThreeQ 的多 seed 可比较实验；
- `experiments/mnist_suite`：MNIST 小预算压力筛查，包含 BP MLP/CNN、ThreeQ、EPThreeQ、DThreeQ、CNNThreeQ；
- `experiments/mnist_legacy_repro` 与 `mnist_epthreeq_tune`：直接调用 legacy 类复现原始 ThreeQ/EPThreeQ；
- 多个 `mnist_dthreeq` 系列 suite：DThreeQ focused、longrun、objective、activation、prediction、input-supervision 与 full-data 检查；

- `experiments/mechanism_diagnostic` 与 `dplus_fix_diagnostic`：同一 mini-batch 上比较 Dplus、BP、EP 的更新方向与 one-step loss decrease。

5 收敛性与发散性实验

5.1 非线性 legacy 推断

图 1 显示，当 $L_g = 5, 8, 10$ 时，后期 $\rho(J)$ 明显低于 1，推断残差下降到 10^{-5} 或更低；当 $L_g = 12$ 时仍低于 1 但收敛显著变慢；当 $L_g = 15$ 时最终 $\rho(J) > 1$，残差停留在约 1.7×10^{-1}，没有进入固定点收敛区间。

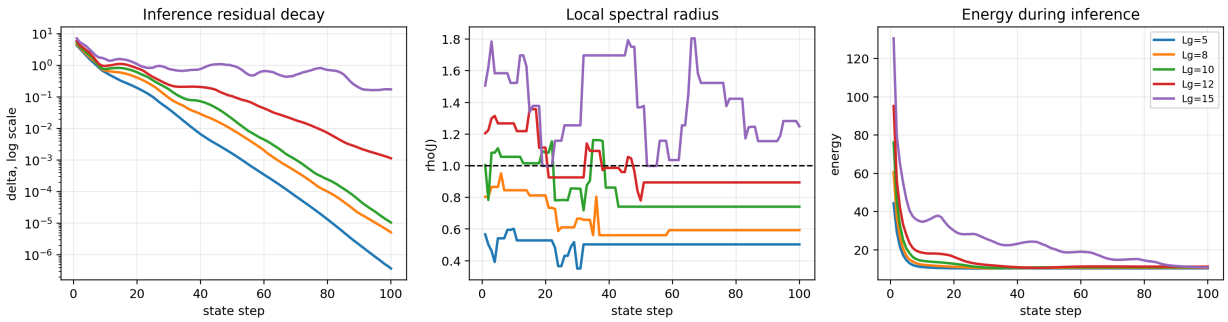

图 1: legacy ThreeQ 非线性推断实验。$\rho(J) < 1$ 的曲线呈残差衰减；$L_g = 15$ 后期 $\rho(J) > 1$，表现为非收敛/慢收敛边界。

表 1: legacy 推断边界实验摘要。

L_g	initial Δ	final Δ	final ρ	reduction	classification
5.0000	4.2969	3.72e-07	0.5029	8.66e-08	convergent
8.0000	4.7041	5.18e-06	0.5929	1.10e-06	convergent
10.0000	5.2755	1.07e-05	0.7411	2.02e-06	convergent
12.0000	5.9884	0.0012	0.8945	1.92e-04	non_convergent_or_slow
15.0000	7.1753	0.1739	1.2486	0.0242	non_convergent_or_slow

5.2 受控线性推断：$\rho > 1$ 的指数发散

为了严格隔离谱半径条件，设 $g(u) = u$，并取 $W = (n-1)\rho I$。此时 $T(u; W) = \rho u$，固定点为 $u^\star = 0$，且 $J = \rho I$。图 2 中 $\rho = 0.80, 0.95$ 时扰动范数下降，$\rho = 1.05, 1.20$ 时扰动范数指数增长。

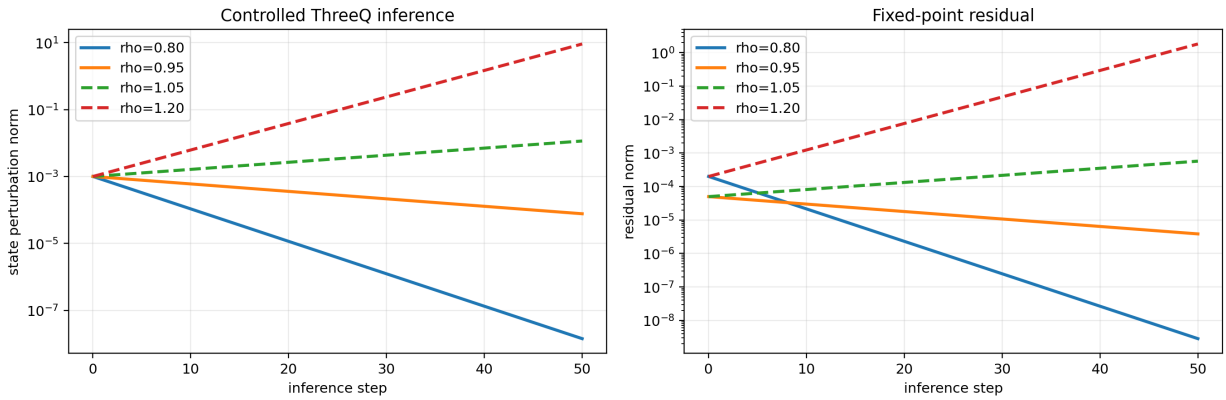

图 2: 受控线性 ThreeQ 推断实验。在同一固定点更新形式 $u_{t+1} = T(u_t; W)$ 下，$\rho < 1$ 收敛，$\rho > 1$ 发散。

表 2: 受控线性推断实验摘要。初始扰动范数为 10^{-3}。

case	ρ	initial norm	final norm	growth factor	final residual
stable_rho_0p80	0.8000	0.0010	1.43e-08	1.43e-05	2.85e-09
stable_rho_0p95	0.9500	0.0010	7.69e-05	0.0769	3.85e-06
unstable_rho_1p05	1.0500	0.0010	0.0115	11.4674	5.73e-04
unstable_rho_1p20	1.2000	0.0010	9.1004	9.10e+03	1.8201

5.3 训练更新压力测试

图 3 展示 bounded-gradient 更新的边界行为。small-step 轨迹从 $\rho = 0.70$ 增加到 0.94，始终满足 $\rho < 1$；large-step 轨迹在第 9 个 epoch 首次达到 $\rho \geq 1$，最终 $\rho = 1.54$，最后一轮推断的扰动范数显著增长。

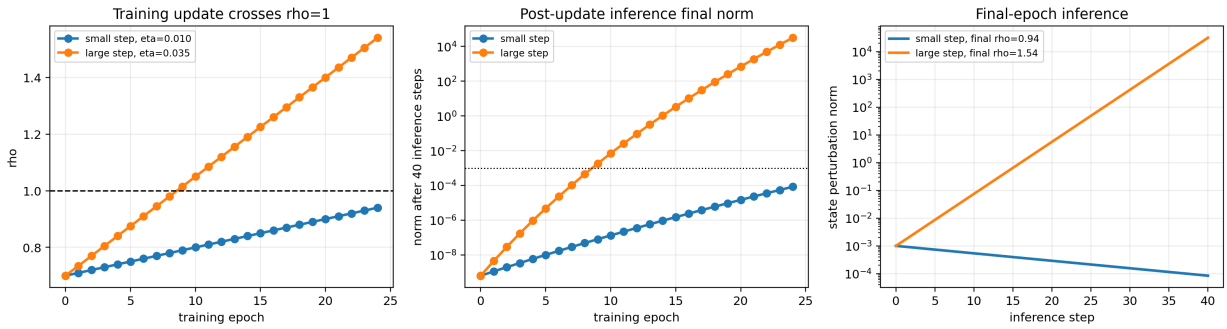

图 3: 训练更新压力测试。左：训练更新使 ρ 变化；中：每轮更新后推断 40 步的最终扰动范数；右：最后一轮参数下的推断轨迹。

表 3: 训练更新压力测试摘要。

case	η	initial ρ	final ρ	first $\rho \geq 1$ epoch	growth factor	final norm
small_step_eta_0p010	0.0100	0.7000	0.9400		0.0842	8.42e-05
large_step_eta_0p035	0.0350	0.7000	1.5400	9.0000	3.17e+07	3.17e+04

6 ThreeQ 与 EPThreeQ 实验现象

图 4 汇总 legacy ThreeQ/EPThreeQ 的 MNIST 训练曲线。EPBase3Q 在 5k/1k、8 epoch 中达到 77.5% best validation accuracy，而 Base3Q 为 60.2%；进一步在 10k/2k、15 epoch 中调参，EPThreeQ 的 best accuracy 达到约 86.5%。训练中的 `rho_mean` 保持在 1 以下，与局部稳定性命题一致。

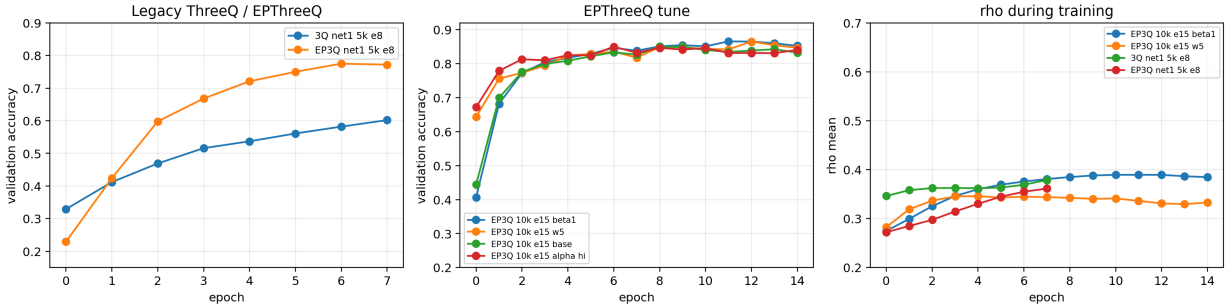

图 4: legacy ThreeQ/EPThreeQ MNIST 训练曲线与训练过程中的 ρ。

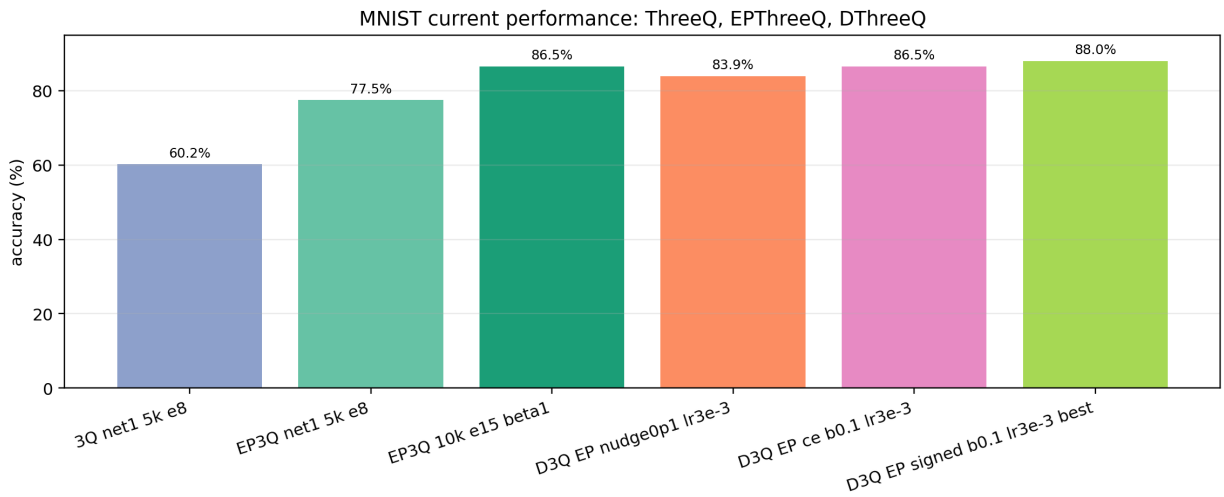

图 5: MNIST 当前性能总览。EPThreeQ legacy 路线和 DThreeQ CE/full-data 路线明显优于小预算公共 ThreeQ screen。

表 4: 关键性能结果摘录。accuracy_used 优先使用 selected accuracy，否则使用 best accuracy。

section	dataset	family	variant	best acc.	selected acc.	accuracy used	final error
two_moons_minimal	2D moons, 3 seeds	EPThreeQ	ep_cost_w50	0.8217		0.8217	0.2817
two_moons_minimal	2D moons, 3 seeds	ThreeQ	direct_cost_w10	0.6067		0.6067	0.4600
mnist_epthreeq_tune	MNIST 10k/2k, 15 epochs	EPThreeQ legacy	epbase3q_legacy_10k_e15_beta1	0.8655	0.8655	0.8655	0.1475
mnist_dthreeq_supervision	MNIST 10k/2k, 30 epochs	DThreeQ	dthreeq_ep_ce_nudge0p1_lr3e3	0.8684	0.8655	0.8655	0.1345
mnist_dthreeq_supervision	MNIST 10k/2k, 30 epochs	DThreeQ	dthreeq_ep_nudge0p1_lr3e3	0.8394	0.8354	0.8354	0.1646
mnist_dthreeq_longrun	MNIST 10k/2k, 30 epochs	DThreeQ EP	dthreeq_ep_nudge0p1_lr3e3	0.8394	0.8394	0.8394	0.1646
mnist_legacy_repro	MNIST 5k/1k, 8 epochs	EPThreeQ legacy	epbase3q_legacy_net1_5k_e8	0.7750	0.7750	0.7750	0.2280
mnist_legacy_repro	MNIST 5k/1k, 8 epochs	ThreeQ legacy	base3q_legacy_net1_5k_e8	0.6020	0.6020	0.6020	0.3980
mnist_dthreeq_fullbudget	MNIST 60k/10k, 30 epochs	DThreeQ	dthreeq_ep_ce_nudge0p1_lr3e3	0.8790	0.8148	0.8148	0.1852
mnist_dthreeq_fullbudget	MNIST 60k/10k, 30 epochs	DThreeQ	dthreeq_ep_nudge0p1_lr3e3	0.8523	0.1632	0.1632	0.8368
mnist_dthreeq_fullbudget	MNIST 60k/10k, 30 epochs	DThreeQ	dthreeq_ep_signed_nudge0p1_lr3e3_restorebest	0.8803	0.8803	0.8803	0.1621

ThreeQ 的主要经验现象是：模型并非不能学习 MNIST，但收敛速度明显慢于 BP，且对 hidden size、状态步数、weak phase、β 和训练预算高度敏感。EPThreeQ 相比 direct ThreeQ 更稳定，因为自由相/受扰相差分提供了更明确的局部学习信号。

7 DThreeQ 改进过程与当前瓶颈

图 6 和图 7 展示 DThreeQ 从 small-budget 失败到 full-data restore-best 约 88.0% 的改进路径。小预算公共框架下 DThreeQ 接近随机；扩大到 legacy 尺度后，EP-nudge 可到约 80.4%；30 epoch longrun 到约 83.9%；CE-style output nudge 在 10k/2k 上达到约 86.5%；full-data restore-best 达到约 88.0%，但 final accuracy 明显回退。

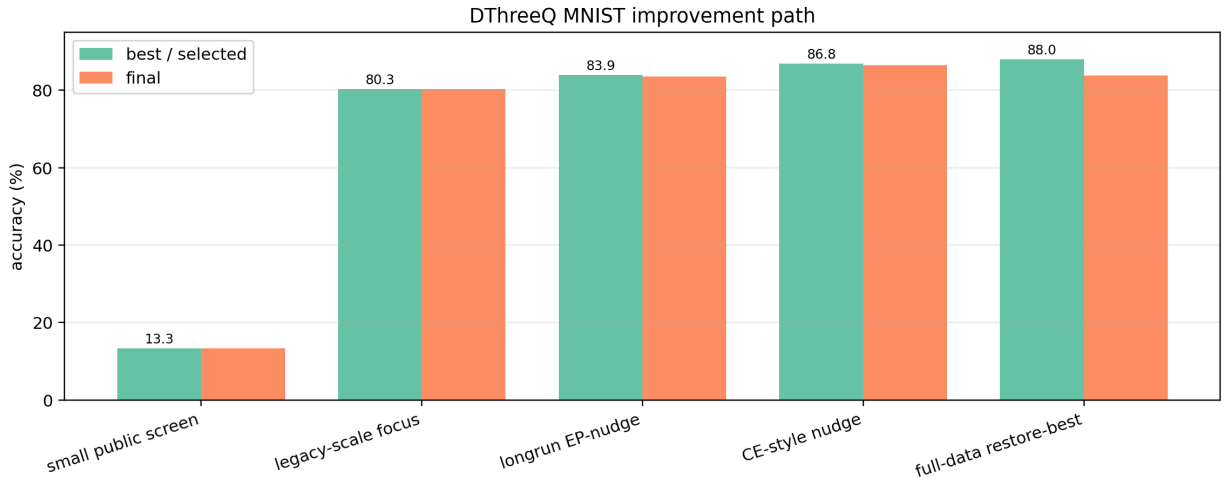

图 6: DThreeQ 从小预算失败到 full-data restore-best 的改进过程。

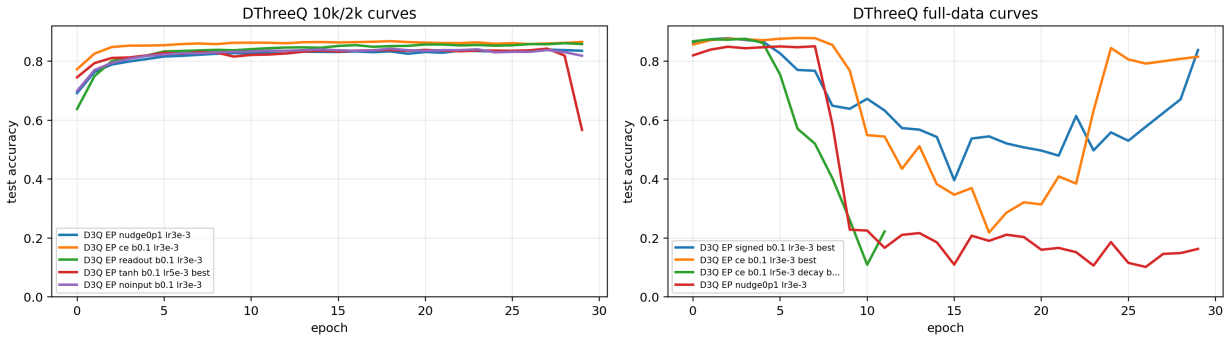

图 7: DThreeQ 10k 与 full-data 训练曲线，显示 early-best 与后期崩塌现象。

表 5: DThreeQ 改进过程分阶段摘要。

stage	variant	dataset	best acc.	final acc.	interpretation
small public screen	dthreeq_ep_nudge_0p01	3k/1k, 3 epochs	0.1332	0.1332	公共框架小预算接近随机，不能代表原始设定。
legacy-scale focus	dthreeq_ep_nudge0p1_lr1e3	10k/2k, 12 epochs	0.8035	0.8035	放大 hidden size 与训练预算后离开随机。
longrun EP-nudge	dthreeq_ep_nudge0p1_lr3e3	10k/2k, 30 epochs	0.8394	0.8354	稳定 baseline 约 83.5% 到 83.9%。
CE-style nudge	dthreeq_ep_ce_nudge0p1_lr3e3	10k/2k, 30 epochs	0.8684	0.8655	输出监督从 MSE nudge 改为 CE-style 后到约 86.5%。
full-data restore-best	dthreeq_ep_signed_nudge0p1_lr3e3_restorebest	60k/10k, 30 epochs	0.8803	0.8379	best checkpoint 达 88.0%，但 final 仍回退。

当前 DThreeQ 的结论需要分开表述：EP/CE-nudge 分支已经是可行路线，但 Dplus residual-delta 规则还不能解释外部 90%+ 结果。若外部 DThreeQ 能稳定超过 90%，最可能差异来自 CE/softmax 输出、best checkpoint、完整数据预算、额外 readout/pretraining、layer-normalized energy 或更强的后期稳定化。

8 Dplus/BP/EP 机制诊断

机制诊断在同一 mini-batch 和同一初始参数上比较 Dplus、BP、EP 的更新向量，统计 cosine similarity、norm ratio、sign agreement 和 one-step loss decrease。图 8 与图 9 显示：Dplus 与 BP 的 forward cosine 只有约 0.03 到 0.08，sign agreement 接近随机；Dplus 与 EP 在 one-sided plus target 上高度同向，但 norm ratio 极小；plusminus 变体出现明确方向抵消。

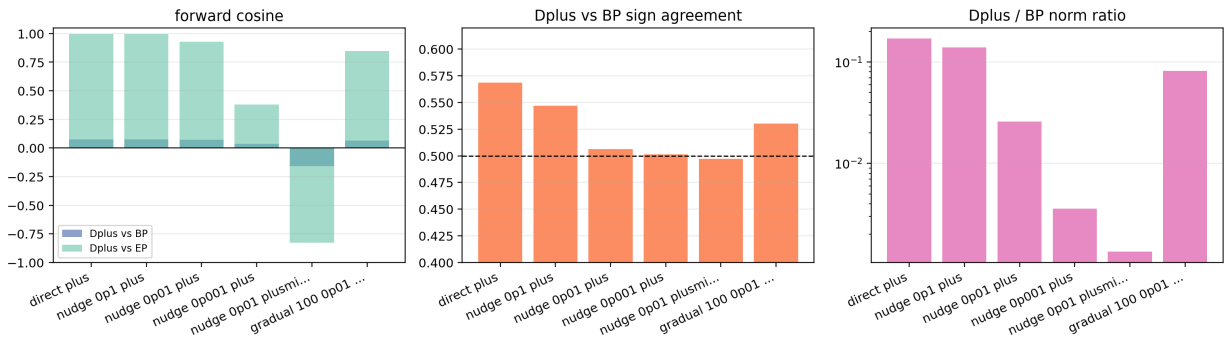

图 8: Dplus、BP、EP 更新向量方向诊断。

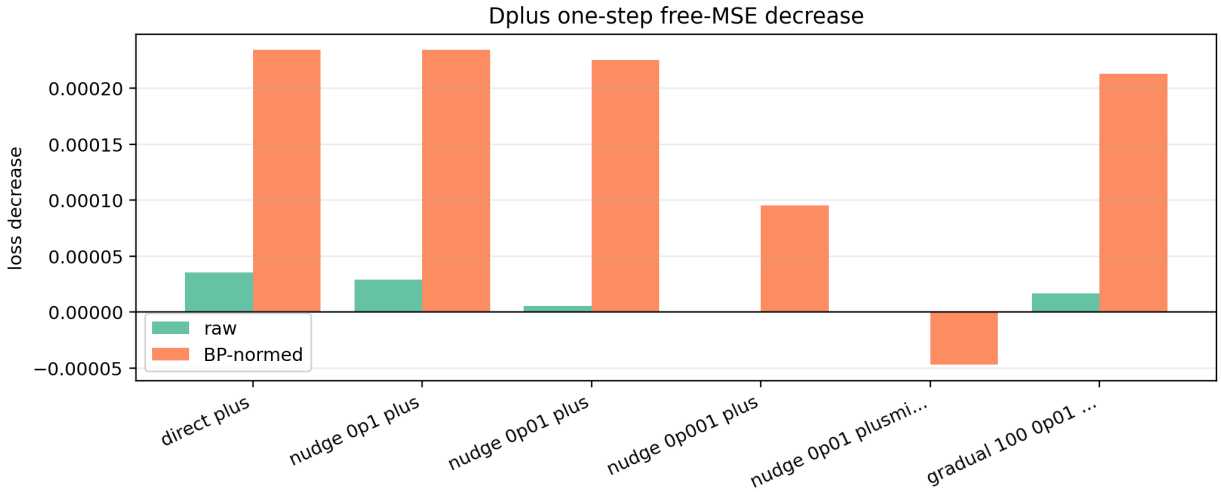

图 9: Dplus one-step loss decrease 与 plusminus 失败模式。

表 6: Dplus 机制诊断关键指标。

target	BP cosine	BP norm ratio	BP sign	EP cosine	EP norm ratio	raw free-MSE decrease
direct_plus	0.0760	0.1705	0.5685	0.9971	0.0831	3.57e-05
nudge_0p1_plus	0.0750	0.1393	0.5468	0.9967	0.0083	2.92e-05
nudge_0p01_plus	0.0711	0.0259	0.5064	0.9276	7.70e-04	5.37e-06
nudge_0p001_plus	0.0363	0.0036	0.5013	0.3804	2.55e-05	6.73e-07
nudge_0p01_plusminus	-0.1574	0.0013	0.4973	-0.8290	4.62e-05	-2.96e-07
gradual_100_0p01_plus	0.0642	0.0817	0.5303	0.8466	6.99e-04	1.67e-05

表 7: Dplus 修正诊断候选。Residual normalization、scale calibration 和 layer-wise gain 主要改变尺度，尚未改变 BP-like 方向。

objective	target	BP cosine	BP sign	BP norm ratio	EP cosine	BP-scaled free-MSE decrease
resnorm_layergain_beta_div1	direct_plus	0.0762	0.5685	7.62e+03	0.9975	4.27e-04
layergain_beta_div1	direct_plus	0.0761	0.5685	0.1705	0.9973	4.28e-04
resnorm_beta_div1	direct_plus	0.0760	0.5685	7.62e+03	0.9972	4.27e-04
resnorm_beta_div2	direct_plus	0.0760	0.5685	7.62e+03	0.9972	4.27e-04
raw	direct_plus	0.0760	0.5685	0.1705	0.9971	4.27e-04
beta_div1	direct_plus	0.0760	0.5685	0.1705	0.9971	4.27e-04
beta_div2	direct_plus	0.0760	0.5685	0.1705	0.9971	4.27e-04
resnorm_layergain_beta_div1	nudge_0p1_plus	0.0752	0.5468	6.23e+04	0.9972	4.27e-04

9 输入能量、输出监督与后期崩塌

图 10 汇总 input reconstruction energy 与分类监督的关系。结果显示，输入重构项确实占据较大能量比例，但简单移除或按 1/784 缩放并不能提升 accuracy，反而降低最终表现。这说明输入项既可能压制监督，也在维持表示结构。更合理的方向是 boundary-clamped input、per-layer normalized energy、output CE nudge 和保守 learning-rate schedule。

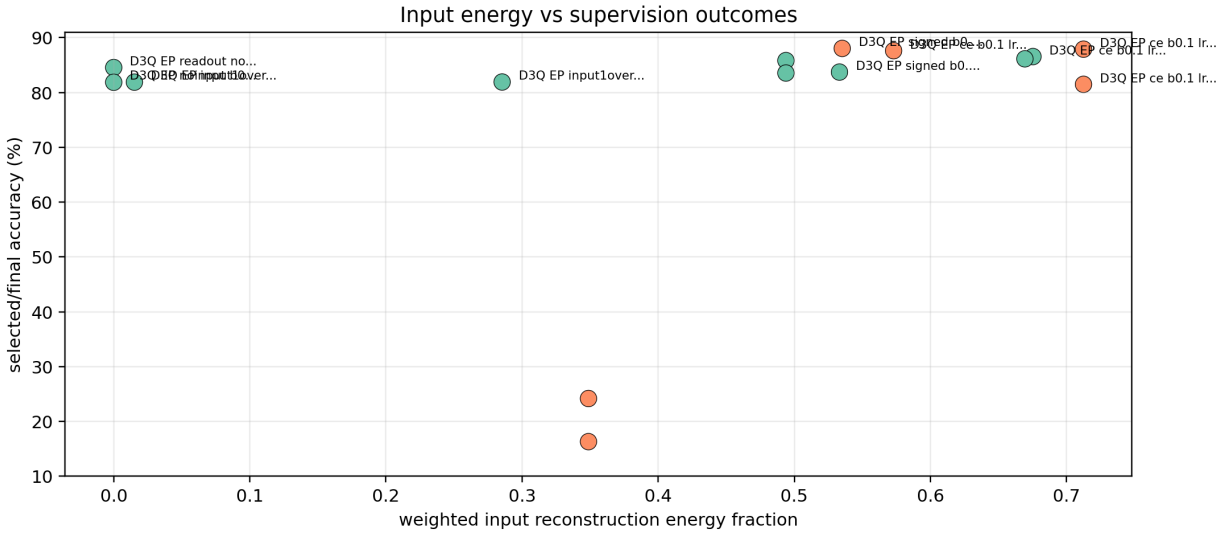

图 10: 输入重构能量比例与分类 accuracy 的关系。

CE-style output nudge 是当前最明确的正向改动：10k/2k 上把 DThreeQ selected accuracy 提高到约 86.5%，full-data restore-best 可达约 87.9%。但 full-data final accuracy 仍会退化，说明仅改监督形式不足以解决后期 saturation、weight drift 或状态轨迹漂移。

10 CNNThreeQ 与对称结构推广

CNNThreeQ/EPCNNThreeQ 使用卷积/反卷积作为局部双向预测，是严格对称结构的重要推广。图 11 汇总 legacy two-moons decision-boundary 图。该组图说明卷积/反卷积形式可以嵌入 ThreeQ 框架，但由于缺少多 seed、统一预算和机制诊断，不能把 legacy 图作为性能排名证据。

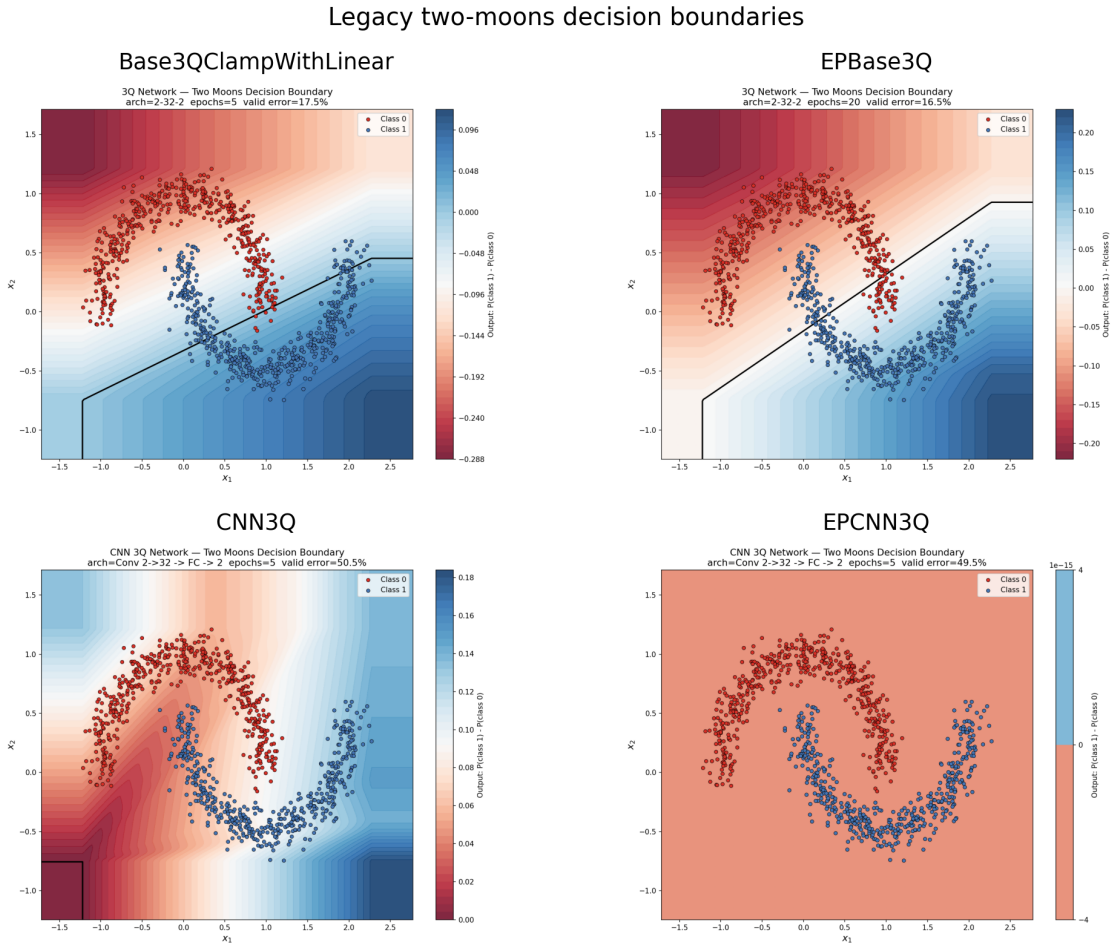

图 11: legacy two-moons decision-boundary 图。CNNThreeQ/EPCNNThreeQ 是结构推广线索，但需要独立可比较 suite 验证。

表 8: MNIST small-budget screen 中 BP、ThreeQ、EPThreeQ、CNNThreeQ 的对照。该表用于说明短预算公共框架失败形态，不代表 legacy 完整预算结论。

variant	family	best acc. mean	final acc. mean	saturation	duration sec
bp_mlp_tanh	bp_mlp	0.8886	0.8886		33.6811
bp_cnn	bp_cnn	0.8812	0.8812		33.4429
epcnnthreeq_ep	legacy_conv	0.1283	0.1283		38.5599
cnnthreeq_direct	legacy_conv	0.1241	0.1195		38.3474
epthreeq_cost_w10	threeq_mlp	0.0957	0.0957	0.4517	45.1293
threeq_direct_cost_w10	threeq_mlp	0.0837	0.0837	0.3859	44.2015

未来 CNNThreeQ 应建立独立 `experiments/cnn_suite`：固定数据、seed、batch、推断步数、学习率和诊断指标，并记录 best/final error、state delta、rho 或替代谱指标、saturation、weight scale 和 runtime。更关键的是，卷积版本不应让所有像素 reconstruction 与分类项同权；应测试 patch/block energy、channel-wise normalization、pooling state 和高层 supervised nudging。

11 总体结论

1. **ThreeQ inference 的理论与实验闭环已经较清楚。** $\rho(J) < 1$ 是局部收敛的可观测充分条件；受控线性实验补足了 $\rho > 1$ 的指数发散证据；训练压力测试说明大步更新可以跨越稳定边界。

2. **基础 ThreeQ 能学习，但慢且敏感。**原始 ThreeQ 不是无法学习 MNIST；问题在于 hard clipping、局部平均预测和 detach 使训练效率低，公共小预算设置会严重低估 legacy 架构。

3. **EPThreeQ 是当前最稳的原始改进线。** EPBase3Q 在 10k/2k、15 epoch 上达到约 86.5% accuracy，且训练中的 ρ 保持在稳定区间。

4. **DThreeQ 的 EP/CE-nudge 分支可行。** DThreeQ full-data restore-best 达到约 88.0%，但 final 退化；Dplus 主规则未通过机制诊断，与 BP 方向不对齐，plusminus 已明确失败。

5. **CNNThreeQ 是结构推广方向，不是当前性能结论。** Conv/ConvTranspose 结构自然对应严格转置共享，但仍需要独立 benchmark。

12 下一步研究方向

后续研究应优先推进五件事。第一，完整复现 legacy MNIST：把 EPBase3Q 的 `beta=1.0` 与 `weak_steps=5` 扩展到 50k/10k、多 seed、保存 best checkpoint。第二，在公共框架逐项对齐 legacy hidden size、状态步数、ϵ、β、初始化和训练预算，定位 small-budget 退化来源。第三，对 DThreeQ 使用 CE/softmax nudge、boundary-clamped input、layer-normalized energy 和 conservative schedule，目标是保住 full-data early best。第四，Dplus 方向需要结构性目标而非继续调尺度，例如 signed residual target、output-to-hidden residual injection 和带约束的 trainable layer gain。第五，CNNThreeQ 应从 energy 粒度重新设计，而不仅是把 MLP 边替换成卷积/反卷积。

13 局限性

本报告汇总的是截至当前仓库已有结果，其中部分 CNNThreeQ 图来自 legacy 脚本，不具备和 radas suite 相同的统计强度；DThreeQ full-data 结果显示 best checkpoint 和 final checkpoint 差异较大，因此不能只报告 selected accuracy；$\rho > 1$ 的严格发散证据来自受控线性母模型，真实非线性 ThreeQ 中可能表现为振荡、停滞或饱和下的退化固定点，而不一定无界爆炸。论文写作中应保留这些边界条件。